PORTFOLIO

실무와 데이터를 연결하는 구조를 설계하여
누구나 신뢰하고 활용할 수 있는 데이터 기반 의사결정에 기여하겠습니다.

Name

차 지 수

Email

smilinggkgk77@gmail.com

Projects

1. 세종 신도시 상가 공실률 예측

2. 이커머스 시즌 별 광고 키워드 가이드

PROJECT_1

[LH 데이터 분석 공모전 대상·우수상 수상]

세종 신도시 상가 공실률 예측

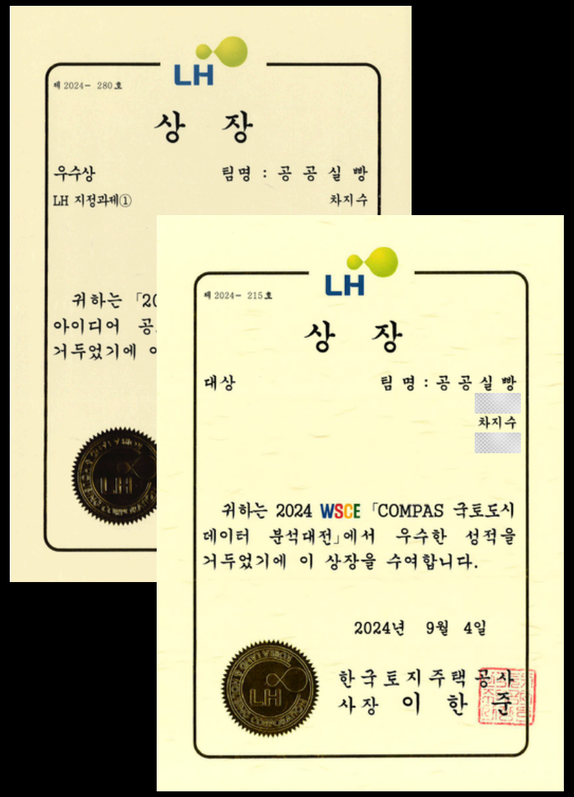

2024. 07(약 8주)

분석 요약

분석배경	최근 경기 침체, 전자상거래의 급속한 성장 등으로 **폐업 상가 증가**로 인한 **상가 공실률의 증가가 사회 문제로 대두**됨. 특히, **신도시의 경우** 과도한 공급, 인구 유입의 지연, 상권 형성의 실패 등으로 인해 **이러한 문제를 피해 가지 못하고 있음**.
분석목표	2025년 신도시 상가 계획 및 관련 정책에 활용하기 위한 신도시 내 상가 건물의 공실률 추정

분석과정

1. 공실률 산출

- 법정동 별 공실률 계산
  - 건물 별 영업 중 상가 정보 데이터 활용
- 공실률 신뢰성 확인
  - 한국감정원 공실률과의 절대오차 비교

2. 공실 증감에 영향을 미치는 인자 추출

- 다중공선성 처리
  - VIF, 상관 분석
- 인자 추출(회귀 분석)
  - PanelOLS Random Effects Model

3. 공실률 예측 모델링

- 인자 간 시점 일치
  - VAR 모델 적용 유동인구, 거주인구 예측
- 예측 모델 선정 및 모델링
  - Bidirectional LSTM

분석 결과

- 공실 증감에 영향을 미치는 인자 13개 추출
- 세종시 신도시 법정동 별 공실률 예측: 공실률 **예측값과 실제값의 오차범위 ± 1.95%**

성과

- **2024 LH 국토도시 데이터 분석대전 대상**
- **2024 LH 신도시 지역의 상가 공실률 추정과제 우수상**

관련기사

- LH 국토도시 데이터 분석 경진대회 열어, '상가 공실률 예측' 대상 수상

활용 데이터 및 전처리

활용 데이터 (공공 데이터)

1. 유동인구.csv	2,064,947 rows	4. 세종시 격자(매핑용).geojson	47,396 rows	6. 세종시 연속지적도.geojson	205,434 rows
2. 상가(상권)정보.csv	13,439 rows	5. 건축물대장.csv	38,075 rows	7. 신도시 법정동 경계.csv	23 rows
3. 거주인구(격자).csv	189,584 rows				

전처리 지역별 공실률 산출을 위해 '7. **신도시 법정동 경계.geojson**'과의 **Spatial Join** 등을 통하여 **신도시 내 23개 법정동 정보 추출**

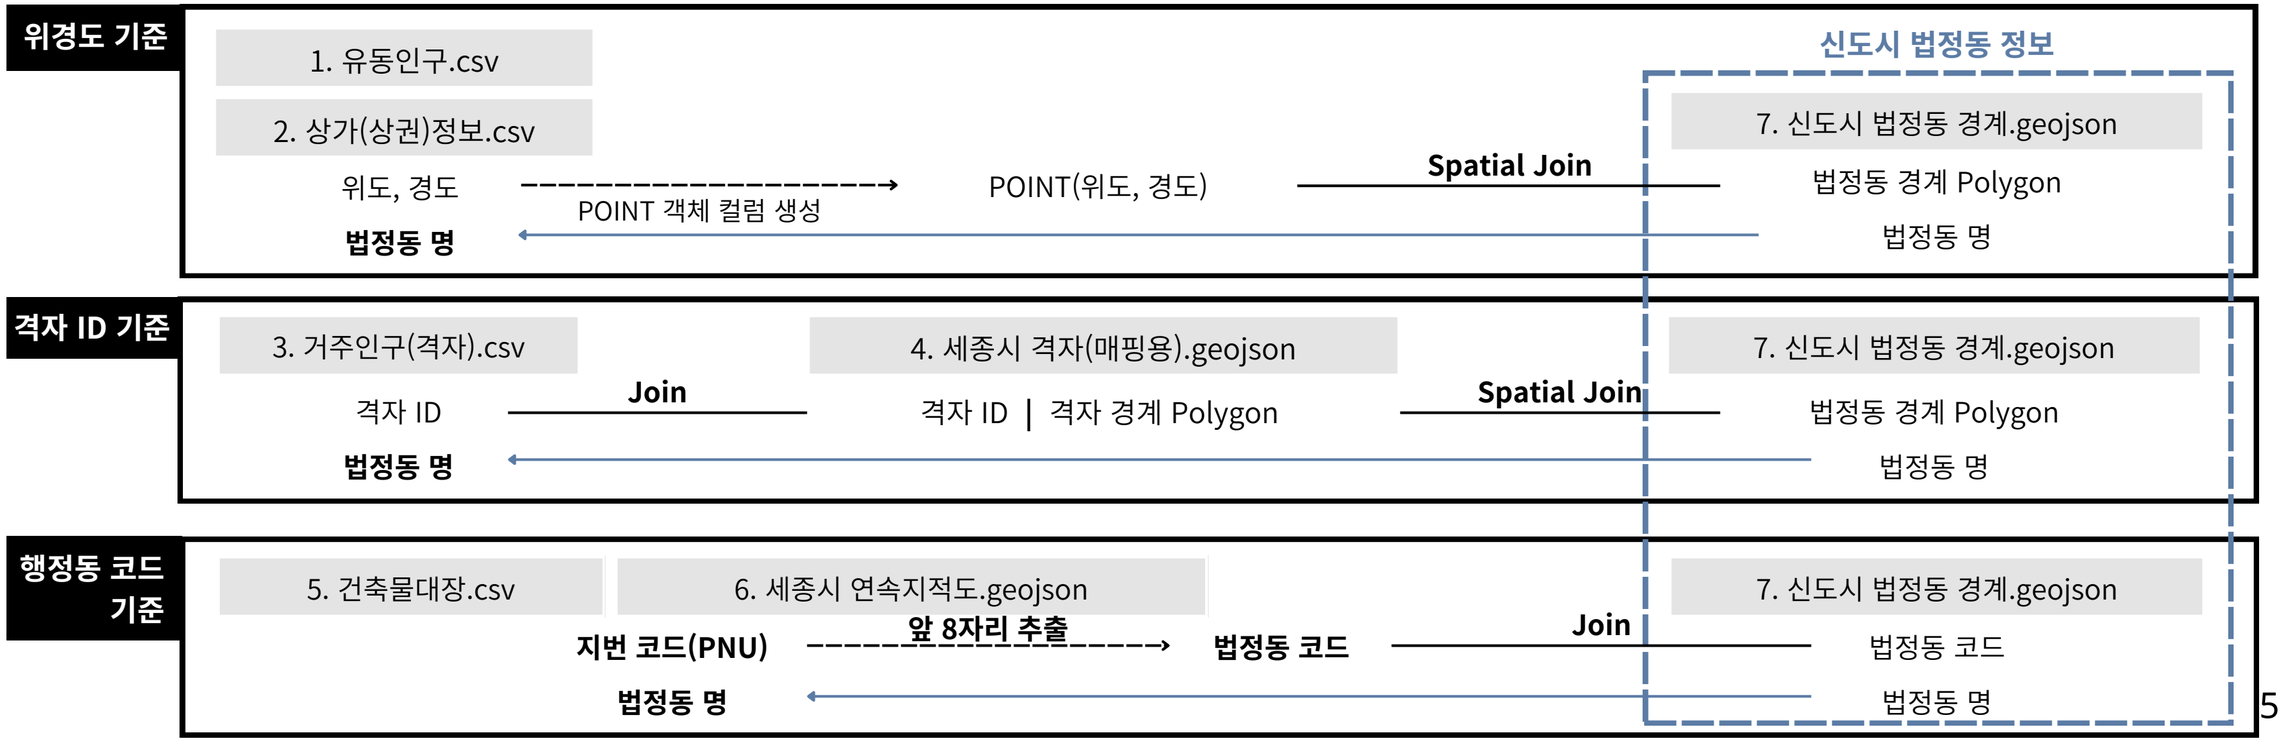

1. 공실률 산출

- 산출기간: 2020년 1월 ~ 2024년 1월
- 수집 기관에 따라 **데이터 간 면적의 기준이 달라 건물 면적이 아닌 상가 수로 공실률을 계산**
- **한국감정원이 발표한 공실률**과의 비교 결과 **절대 오차의 평균이 3.7%**임을 확인

산출방식

$$[1 - (\frac{\text{분기별 총 영업 중 상가 수}}{\text{전체 기간 최대 영업 중 상가수}})] * 100$$

- 데이터: 2. 상가(상권)정보.csv
  - 분기 별 영업 중인 상가 정보 데이터
- 건물관리번호 컬럼으로 건물 식별
- 건물 면적의 경우 데이터 별 기준이 달라 사용 불가
- 기간 내 건물 별 영업 중 상가 수의 최대값을 각 건물의 총 상가 수로 가정

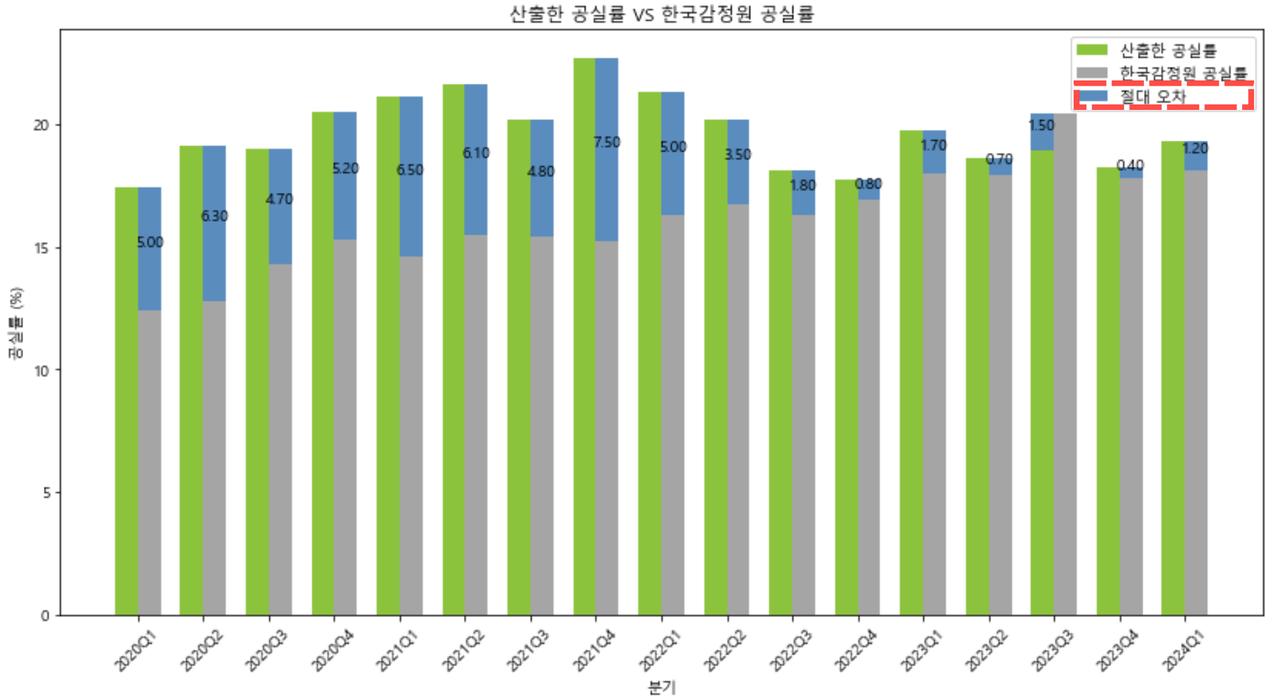

* 참고문헌: 이재경, 「지역경제 및 상권활성화 연계된 서울시 상가 공실률 추정 :연구용역」, 「서울신용보증재단」, 2020, 16p

2. 공실 증감에 영향을 미치는 인자 추출

① **인자 후보 선정**: 상가 공실률 관련 문헌 참고하여 인자 선정 (24개)

② **1차, 2차 다중공선성 완화**: (1차) VIF, 상관 관계 고려하여 1개 인자 제거 후 (2차) 23개 병합하여 동일한 과정을 통해 2개 인자 제거

③ **회귀 분석**: 패널 데이터 특성을 고려해 PanelOLS Random Effects Model 활용 최종 인자 13개 추출

Bresh-Pagan LM Test 결과 랜덤효과 유의미함

*p-value < 0.05인 인자. 유동인구의 경우 p-value 0.0566으로 유의미하다고 판단

VIF값 확인

feature	VIF
const	0.0
상가 아님	inf
소규모	inf
오피스	inf
중대형	inf
집합	inf

- 모든 인자 inf

상관 분석

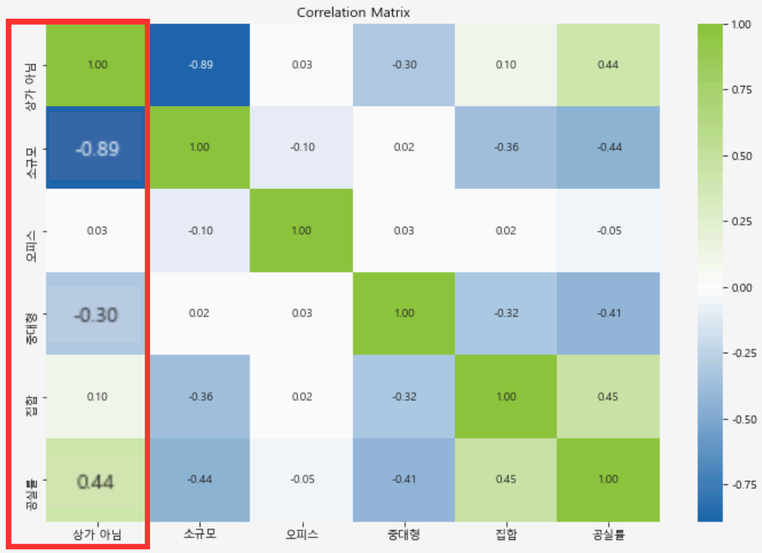

- 다른 인자와 상관관계가 높은 '상가 아님' 제거

최종 인자 후보 추출

feature	VIF
const	3.801881
소규모	1.175148
오피스	1.010276
중대형	1.133028
집합	1.302880

- 4개 인자 추출

다중공선성 완화 예시(상가유형)

구분	변수명
입지 요인 (2)	유동인구
	거주인구
건물 속성 요인 (5)	건축면적
	지상층수
	에너지절감률
	친환경건축물인증점수
	집합 상가 비율
상권 구성 요인 (6)	HHI
	교육 서비스업
	도매 및 소매업
	보건업 및 사회복지 서비스업
	숙박 및 음식점업
	프랜차이즈 비율

최종 추출 인자 (13개)

3. 공실률 예측 모델링

① 유동인구, 거주인구 예측

- 모델: 주성분 분석(PCA) 후 VAR 적용
- 교차 검증: TimeSeriesSplit
- 최적 파라미터
  - 유동인구: 주성분 2개, lag 1개
  - 거주인구: 주성분 3개, lag 1개
- 유동인구 법정동 별 예측 성능
  - 평균 RMSE 10.109, MAE 8.797

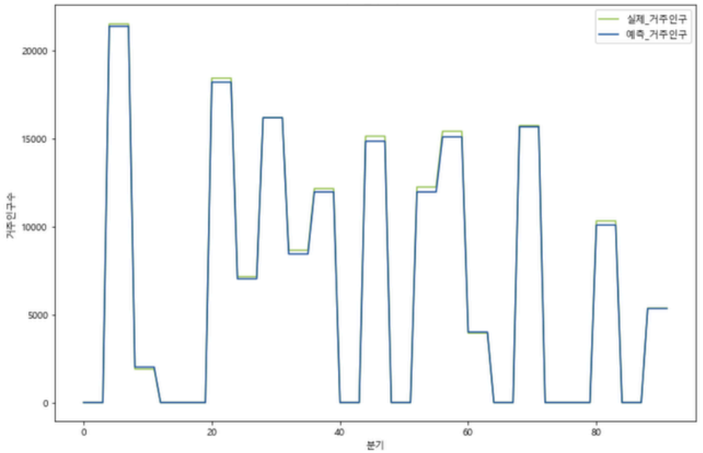

거주인구 검증 데이터에 대한 예측-실제 비교

② 데이터 전처리

- 결측치 처리
  - 상가가 없는 법정동 제거(34 rows)
  - 그 외 평균 대체 (25 rows)
- min-max 정규화
  - Train-Test set 별 단위 차 조정

year_quarter	EMD_NM	공실률
2020Q1	가람동	6.578947
2020Q2	가람동	9.210526
2020Q3	가람동	20.175439
2020Q4	가람동	28.070175
2021Q1	가람동	28.070175
...	...	...
2023Q1	해밀동	80.000000
2023Q2	해밀동	90.000000
2023Q3	해밀동	90.000000
2023Q4	해밀동	90.000000
2024Q1	해밀동	95.000000

year_quarter	EMD_NM	공실률
2020Q1	가람동	0.234375
2020Q2	가람동	0.328125
2020Q3	가람동	0.718750
2020Q4	가람동	1.000000
2021Q1	가람동	1.000000
...	...	...
2023Q1	해밀동	0.842105
2023Q2	해밀동	0.947368
2023Q3	해밀동	0.947368
2023Q4	해밀동	0.947368
2024Q1	해밀동	1.000000

공실률의 min-max 정규화 전후 비교

③ 공실률 예측

- 모델 구성: Bidirectional LSTM, tanh 활성화 함수, loss = MSE, adam 최적화
- 데이터 분할: 67% 학습, 33% 검증, look_back=4
- 성능 최적화: 조기 종료 및 학습률 감소 콜백, epochs=1000, batch_size=64

	MSE	MAE
mean	0.0049551	0.0205069
50%	0.0000153	0.0039126

스케일링된 공실률의
예측값 오차 범위 ± 0.0205
실제 공실률의
예측값과 실제값의 오차범위 ± 1.95%

분석 결과 및 기대효과

- **분석 결과**
  - **공실률 증감에 영향을 미치는 요인 13개 추출**
  - **세종시 신도시 법정동 별 공실률 예측**: 비상업 지역을 제외한 21개 법정동의 분기 별 공실률 예측
- **기대효과**
  - 입지, 건물 속성, 상권 구성 등 공실률 증감에 영향을 미치는 요인을 **데이터 기반의 도시 계획 및 투자를 위한 지표**로 활용
  - 예측된 공실률 데이터를 **상업 지역 개발 우선순위 선정을 위한 기준**으로 활용

종촌동, 한솔동 공실률 추이

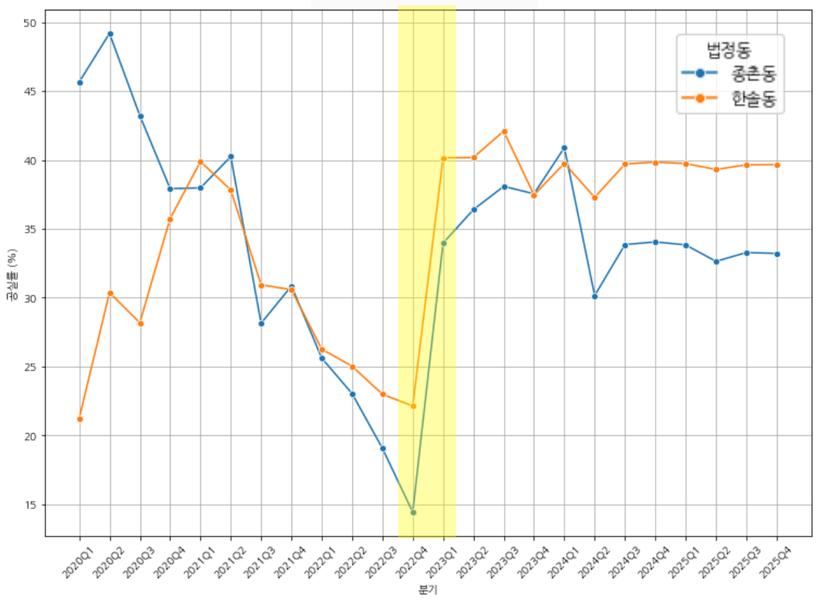

종촌동 업종별 상가 수 추이

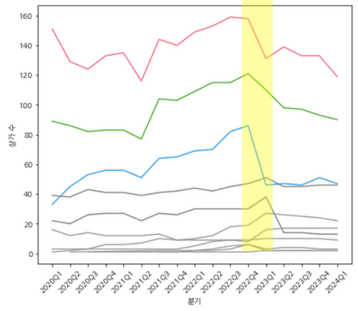

한솔동 업종별 상가 수 추이

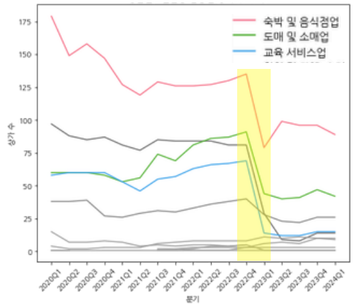

숙박 및 음식점업, 도매 및 소매업, 교육 서비스업의 개폐업에 영향을 받는 종촌동, 한솔동

3생활권 법정동별 공실률 추이

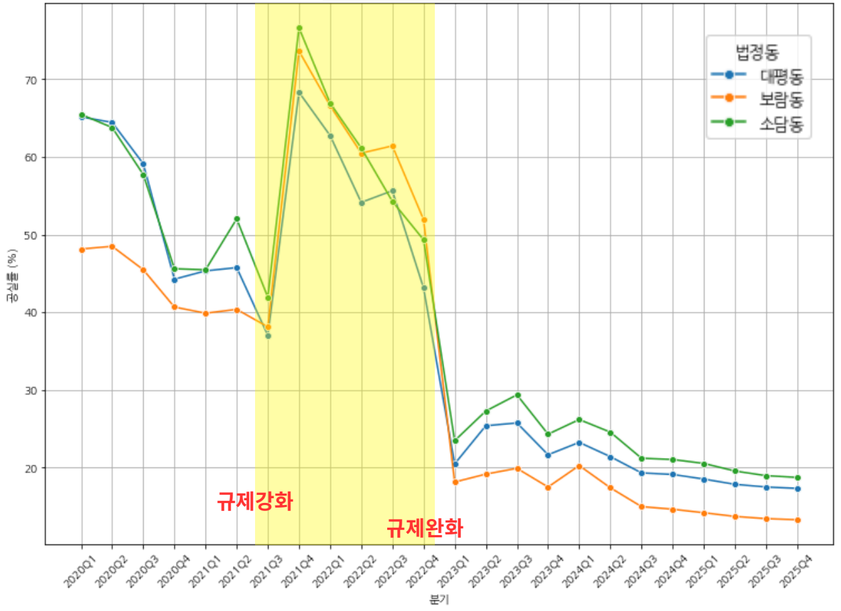

부동산 대출 규제 동향에 영향을 받는 3생활권

PROJECT_2

이커머스 시즌 별 광고 키워드 가이드

(기업 연계)

2024. 06(약 4주)

분석 요약

분석배경

- 분석요청자: 온라인 쇼핑몰 R사 마케터
- **신규 고객에 대한 높은 매출 의존도(86%)**를 보이는 온라인 쇼핑몰 R사. **2024년 이후 매출이 하락세**를 벗어나지 못하고 있음.

문제정의

신규고객 유입에 가장 영향을 주는 **광고 비용을 늘리며 머신러닝 광고 타겟 최적화** 서비스 또한 활용하고 있지만 비용 대비 **효율은 계속해서 떨어지고 있음**.

가설수립

'비용과 타겟 외에 **관리되지 않고 있는 요인인 광고 키워드**가 **광고 효율에 시즌 별로 다른 영향을 미치고 있을 것**이다'

| R사 매출액 대비 광고비 및 ROAS 추이

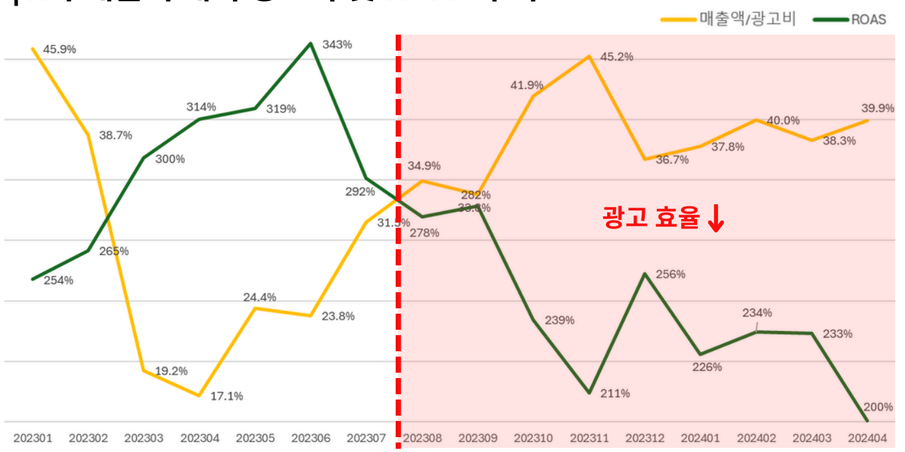

분석과정

1. 광고 키워드 별 구매에 대한 영향력 수치화

- 광고 키워드 간 **다중공선성 완화**
  - 상관 관계 높은 키워드 쌍 결합
- **릿지 회귀 모델링**: 계수 활용 영향력 수치화
  - 적합성 평가: 시즌 **R^2 Score 평균 96.3**

2. 시즌 별 GOOD/BAD 키워드 분류

- 분류 기준 설정
  - 계수, 구매 건수 대비 빈도 기준 설정
- 키워드 별 광고비 대비 구매 건수 분포 확인

3. 키워드 분류의 유의미함 검증

- 이상치 제거
- 등분산 여부 판단(**F-검정**)
  - p-value 0.000132
- **Welch's t-검정** 진행

분석 결과

- **Welch's t-검정 결과** p-value 0.000036로 **GOOD/BAD 키워드 간 유의미한 차이가 있음**을 확인
  - Good 키워드는 Bad 키워드에 비해 **평균 광고비 대비 구매 건수가 약 1.5배**
- R사에서는 제안 내용을 참고하여 **여름 시즌 광고 키워드를 반영한 이벤트 진행**함(2024.7, 10일 간)

1-1. 데이터 전처리

활용 데이터: 기업 제공

- 1~3번 데이터로 EDA 및 현황 파악 후 4. 광고 성과(lookerstudio) 데이터로 광고 키워드 분석 진행

1. 주문 내역.csv	16,114 rows	3. 리뷰 데이터.csv	5,336 rows
2. 고객 정보.csv	4,216 rows	4. 광고 성과(lookerstudio)	2,704 rows

전처리

- 회귀 분석을 위한 동일 광고 소재 별 성과 집계 및 광고 별 키워드 추출, 정제

1. 동일 광고 소재 별 성과 집계
광고 이미지 해시값 생성하여
동일광고 별 집계

→

2. 광고 이미지 키워드 추출
- GPT 활용 1차 추출 후 검증
- 합성명사 분리 및 유사 키워드 통일

→

3. 상관 관계 높은 키워드 쌍 결합
키워드 간 상관 관계로 인한
다중공선성 문제 최소화
결합 전 314개 → **결합 후** 196개

1-2. 모델링

- **모델링 목적**: 광고 키워드 별로 구매 건수에 미치는 영향력을 확인
- **모델 선정**
  - 릿지 회귀 모델 선정: 다차원의 독립변수를 가진 데이터에 적합 (독립 변수인 키워드 총 196개)
- **변수 설정**
  - 독립 변수: 광고 키워드 196개
  - 종속 변수: 구매 건수
- **계절 별 모델 성능**
  - R^2 Score: 모델의 데이터 설명력, 적합성 평가
    - 봄 : 0.96
    - 여름: 0.99
    - 가을: 0.93
    - 겨울: 0.97
- **모델 학습 및 최적화**
  - GridSearchCV 교차 검증: 다차원의 하이퍼파라미터 튜닝을 통해 최적의 alpha 값을 선택
    - scoring: neg_mean_squared_error
    - 교차검증: cv = 5
  - 계절 별 최적 알파 값: 0.1(계절 간 동일)

2~3. 시즌 별 GOOD&BAD 키워드 분류 및 검증

- **시즌 별 GOOD & BAD 키워드 분류**

구분	수	기준
GOOD	15개	계수 0.6 이상, 구매 건수 < 빈도의 경우 제외
BAD	17개	계수 -0.6 이하, 빈도 Q3 이상

- **GOOD & BAD 키워드 간 t-검정 진행**
  - 이상치 제거: GOOD 키워드에서 이상치 3개 제거
  - F-검정: p-value 0.000132, F-통계량 19.60
  - Welch's t-검정: **p-value 0.000036**, t-통계량 4.93

키워드 별 광고비 대비 구매 건수 분포

구매 건수/광고비(천 원)

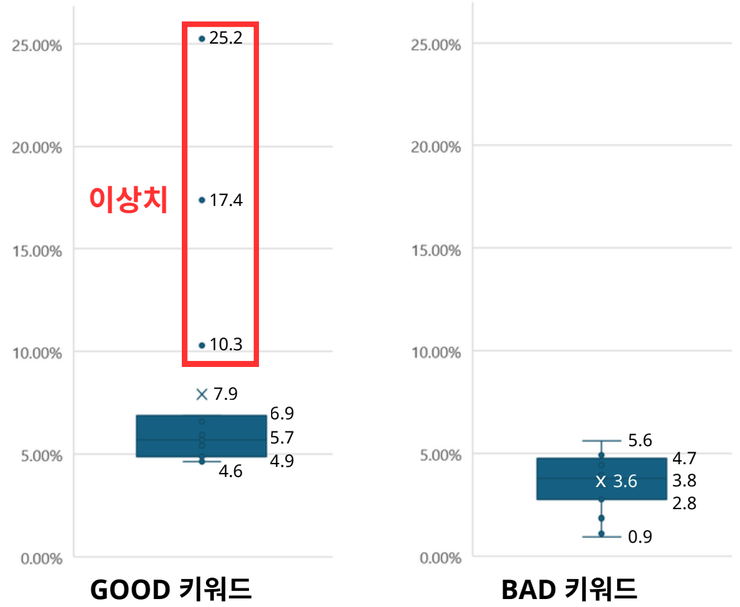

이상치 제거 후 키워드 별 광고비 대비 구매 건수 분포

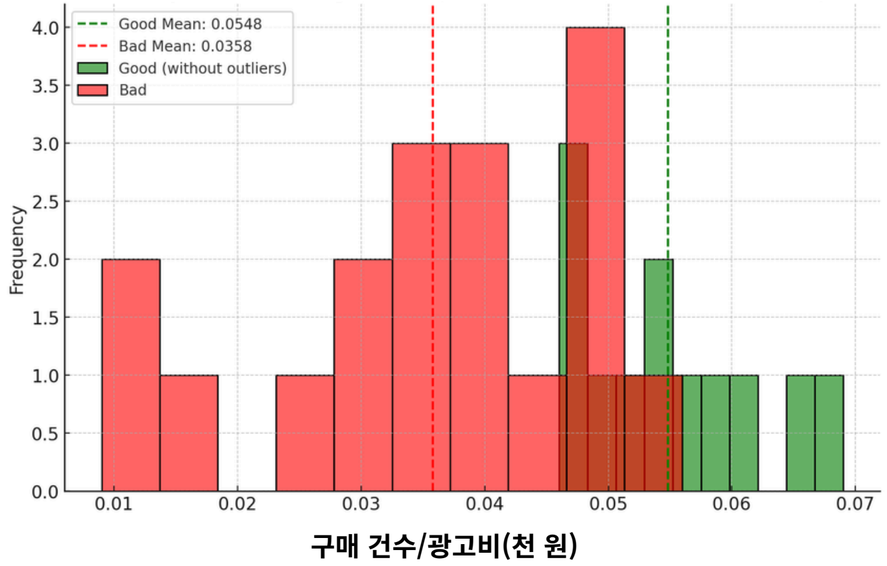

GOOD 키워드의 광고비 대비 구매 건수가 BAD 키워드보다 유의미하게 높음

분석 결과 및 기대 효과

- **분석 결과**
  - Good 키워드는 Bad 키워드에 비해 평균 광고비 대비 구매 건수가 약 1.5배(광고비 1,000원 당 구매 건수 약 19건 많음)
- **기대 효과**
  - 투자 대비 수익률(ROI) 개선: Good 키워드를 활용하여 동일한 광고비로 더 많은 구매 건수를 확보
  - 마케팅 전략 최적화: Good 키워드에 더 많은 예산을 배분하여 광고 캠페인의 전반적 성과 최적화

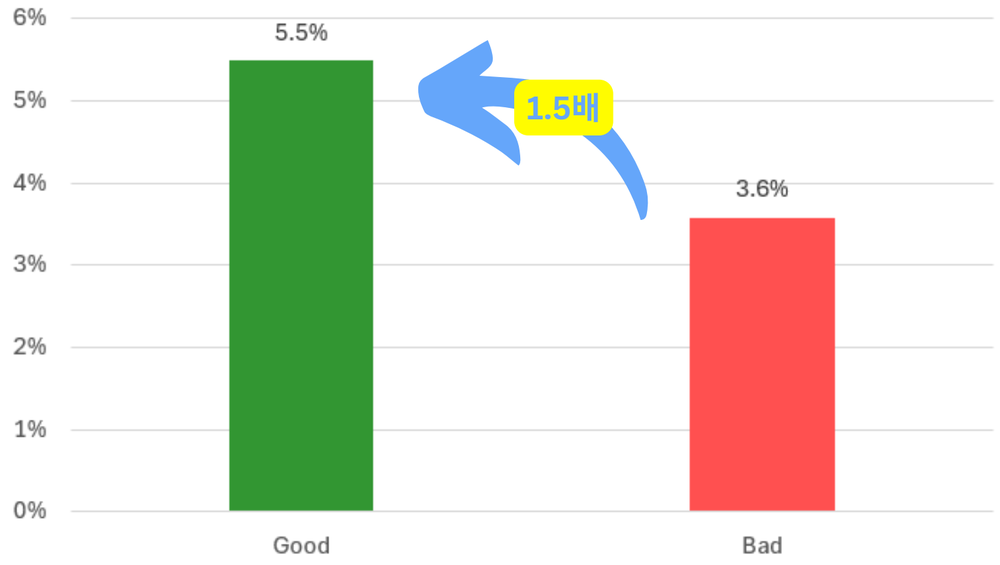

키워드 별 평균 광고비 대비 구매 건수 비교

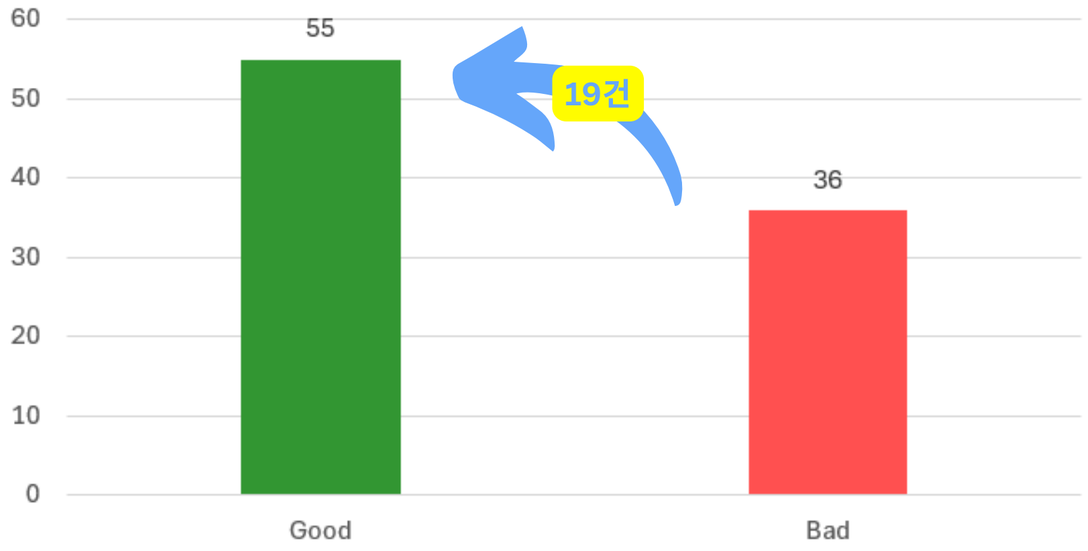

키워드 별 광고비 1,000원 당 구매 건수 비교(건)

E . O . D

Name

차 지 수

Email

smilinggkgk77@naver.com